

Protocolo metodológico

Protocolo computacional para la clasificación de enunciados en el marco de la Gramática Institucional

Versión 1.0, octubre de 2026

Autores

Karina Arias-Yurisch

Escuela de Gobierno, Pontificia Universidad Católica de Chile

Daniel Toro-Cabrera

Facultad de Ciencias Físicas y Matemáticas, Universidad de Chile

Cita sugerida

Arias-Yurisch, K., & Toro-Cabrera, D. (2026). *Protocolo computacional para la clasificación de enunciados en el marco de la Gramática Institucional* (Versión 1.0).

https://github.com/dlatorocabrera/IG_protocol_project

Financiamiento

Este trabajo contó con el apoyo del Concurso de Investigación y Creación Avanza UC 2025 (folio AV25365), Dirección de Investigación, Vicerrectoría de Investigación y Postgrado, Pontificia Universidad Católica de Chile.

Licencia

© 2026 los autores. Esta obra está bajo una licencia Creative Commons Atribución 4.0 Internacional (CC BY 4.0).

<https://creativecommons.org/licenses/by/4.0/>

INTRODUCCIÓN

Este protocolo propone un flujo de trabajo para automatizar la identificación y clasificación en regulativos, constitutivos o no institucionales, de enunciados en documentos legales y de políticas públicas, siguiendo las definiciones del marco de la Gramática Institucional. El alcance de este protocolo se extiende desde la preparación del texto hasta la clasificación. El flujo de trabajo combina procedimientos basados en reglas, modelos de aprendizaje automático supervisado y validación humana para apoyar un proceso transparente, reproducible y escalable en el marco de la Gramática Institucional.

El marco de la Gramática Institucional

La Gramática Institucional (IG, por sus siglas en inglés) fue introducida por Crawford & Ostrom (1995) como una sintaxis teórica para representar sistemáticamente el contenido lingüístico de las instituciones. Desde esta perspectiva, las instituciones constituyen patrones estables de acción humana estructurados por reglas, normas, estrategias compartidas y las condiciones materiales en que ocurren las interacciones sociales. Los enunciados institucionales expresan restricciones u oportunidades compartidas que prescriben, permiten o aconsejan acciones o resultados para actores individuales o colectivos. Al descomponer estos enunciados en componentes sintácticos estandarizados, la IG proporciona una unidad de análisis común para describir y comparar arreglos institucionales entre documentos, ámbitos de política pública, jurisdicciones y períodos.

Posteriores desarrollos de la Gramática Institucional distinguen entre enunciados regulativos y constitutivos. Los enunciados regulativos prescriben o restringen las acciones de los actores, mientras que los constitutivos crean, definen, modifican o asignan propiedades, roles, relaciones o autoridad a entidades dentro de un sistema institucional (Frantz & Siddiki, 2021). En los enunciados regulativos, la sintaxis ABDICO identifica el Atributo (A), o actor al que se aplica el enunciado; el Deóntico (D), que indica si una acción es obligatoria, permitida o prohibida; el Objetivo (I), o acción prescrita por el enunciado; el Objeto (B), que recibe esa acción o se ve afectado por ella; el Contexto (C), que identifica las circunstancias en que se aplica el enunciado o se realiza la acción; y la Consecuencia (Or Else, O), que especifica un enunciado de consecuencia asociado al cumplimiento o incumplimiento. La IG 2.0 distingue, además, dentro del Contexto, las Condiciones de Activación, que determinan cuándo el enunciado en su conjunto pasa a ser aplicable, y las Restricciones de Ejecución, que precisan cómo, dónde, cuándo o en qué medida se realiza el Objetivo. Cuando una Condición de Activación o una Restricción de Ejecución se expresa como un enunciado institucional anidado, puede contener su propia acción y su propio Objeto. Los enunciados constitutivos emplean una sintaxis correspondiente orientada a las entidades, propiedades y funciones que configuran el sistema institucional, y los textos institucionales pueden contener combinaciones anidadas o híbridas de enunciados regulativos y constitutivos (Frantz & Siddiki, 2021). El presente protocolo introduce estas distinciones y la arquitectura ABDICO como marco conceptual para la clasificación de enunciados.

La IG se ha aplicado al análisis de leyes, reglamentos, políticas y otros arreglos institucionales formales e informales. Una revisión de Dunlop et al. (2019) encontró que las primeras aplicaciones utilizaban la gramática principalmente para examinar la configuración textual de documentos de políticas públicas y sistemas de reglas institucionales, en particular en la gobernanza ambiental y de recursos de uso común. Sin embargo, los autores advierten que el recuento de componentes y la codificación descriptiva ofrecen un valor explicativo limitado si no se vinculan con preguntas de investigación fundamentadas teóricamente. Evaluaciones más recientes destacan la versatilidad metodológica de la IG y su capacidad para apoyar análisis cualitativos, cuantitativos, comparativos y computacionales del diseño institucional (Siddiki & Frantz, 2022). En una revisión de 48 estudios empíricos, Pieper et al. (2023) muestran que los datos codificados con IG se han

utilizado para operacionalizar conceptos institucionales complejos como policentricidad, discrecionalidad, autoridad y cumplimiento. Estas aplicaciones demuestran el valor de la IG como un enfoque transparente y sistemático para convertir información institucional textual en datos estructurados, a la vez que destacan la importancia de la interpretación teórica y la validación humana.

Automatización de la codificación con Gramática Institucional

La creciente aplicación de la codificación con Gramática Institucional ha puesto de manifiesto una limitación práctica importante: identificar manualmente enunciados institucionales y descomponerlos en sus componentes sintácticos requiere tiempo considerable, formación especializada y decisiones humanas reiteradas. Los métodos computacionales pueden reducir algunos de estos costos y apoyar el análisis de colecciones documentales más amplias. Sin embargo, la literatura existente no ofrece un único método que automatice todo el proceso de codificación. En cambio, distintos estudios abordan operaciones específicas dentro de un flujo de trabajo más amplio mediante combinaciones de procedimientos basados en reglas, procesamiento del lenguaje natural, aprendizaje automático supervisado, diccionarios y validación humana. Por tanto, la literatura aborda distintas etapas de la automatización de la Gramática Institucional, más que una solución integral de principio a fin.

La siguiente tabla resume las principales estrategias identificadas en la literatura:

Tarea de automatización	Enfoque	Implementación y propósito	Referencias
1. Preparación del texto y estructuración del corpus	Limpieza del texto basada en reglas	Las funciones de búsqueda personalizadas y las expresiones regulares eliminan ruido de formato, puntuación irregular, encabezados y otros artefactos estructurales antes del procesamiento lingüístico.	Rice et al. (2021)
	Filtrado por estructura documental	Los marcadores específicos del documento delimitan el texto normativo sustantivo. Los títulos, considerandos, tablas y apéndices pueden excluirse cuando quedan fuera del alcance analítico.	Brandsma et al. (2025)
	Limpieza y armonización de entidades asistidas por PLN	Las herramientas de procesamiento de texto y reconocimiento de entidades nombradas apoyan la limpieza de caracteres, la expansión de siglas, la identificación de actores y la armonización de distintos nombres que se refieren a una misma organización.	Galik & Johnson (2026)
2. Segmentación de enunciados candidatos	Segmentación de oraciones mediante PLN	Stanford CoreNLP separa los documentos en oraciones y añade anotaciones de categorías gramaticales y dependencias.	Rice et al. (2021)
	Segmentación de oraciones y tokens	spaCy separa el texto en oraciones y tokens antes de generar etiquetas de categorías gramaticales y árboles de dependencias.	Vannoni (2022)

Tarea de automatización	Enfoque	Implementación y propósito	Referencias
	Delimitación manual de enunciados	Los enunciados se delimitan manualmente antes de la clasificación y la anotación de componentes. Esto ofrece mayor control interpretativo, pero limita la escalabilidad.	Wróblewska et al. (2023)
3. Identificación y clasificación de enunciados relevantes	Clasificación mediante aprendizaje automático supervisado	Las representaciones TF-IDF, los n-gramas de palabras seleccionados y un clasificador Random Forest distinguen los enunciados regulativos de los constitutivos.	Wróblewska et al. (2023)
	Análisis de dependencias basado en reglas	Las reglas lingüísticas aplicadas a estructuras de dependencias identifican enunciados que cumplen características regulativas predefinidas.	Brandsma et al. (2025)
	Clasificación basada en transformadores	BERT, LEGAL-BERT e InLegalBERT se entrenan y evalúan como clasificadores alternativos para identificar enunciados regulativos.	Brandsma et al. (2025)
	Selección basada en palabras clave	Las palabras clave identifican enunciados asociados a un tema sustantivo específico de política pública. Esto permite seleccionar por tema, pero no distingue, por sí solo, tipos de enunciados institucionales.	Kim & Collins (2026)
Extensión futura: extracción de componentes de IG (fuera del alcance actual del protocolo)	Extracción basada en diccionarios	Los diccionarios refinados manualmente identifican actores, categorías de reglas y operadores deónticos. Los componentes identificados pueden representarse posteriormente como relaciones diádicas o redes.	Heikkila & Weible (2018)
	Extracción lingüística basada en reglas	Las etiquetas de categorías gramaticales y las relaciones de dependencia generadas con spaCy, Stanza o cleanNLP se vinculan con componentes de la Gramática Institucional mediante reglas lingüísticas explícitas.	Kim & Collins (2026); Vannoni (2022); Wróblewska et al. (2023)
	Extracción de entidades, verbos y elementos deónticos	El reconocimiento de entidades nombradas, la desambiguación de actores, la extracción selectiva de verbos y los diccionarios deónticos identifican elementos específicos de los arreglos institucionales.	Galik & Johnson (2026)
	Clasificación supervisada de tokens	Las características lingüísticas y contextuales de cada palabra se clasifican en categorías de componentes de IG mediante modelos de redes neuronales.	Rice et al. (2021)

Tarea de automatización	Enfoque	Implementación y propósito	Referencias
	Etiquetado de roles semánticos y resolución de correferencias	Los roles semánticos, como agentes, acciones y destinatarios, se vinculan con los componentes correspondientes de IG. La resolución de correferencias recupera actores u objetos a los que se hace referencia en distintas oraciones.	Bushouse et al. (2026)

Flujo general del protocolo

El protocolo se organiza en tres tareas secuenciales e interconectadas. La Tarea 1, Preparación del texto y estructuración del corpus, registra los documentos fuente, extrae y normaliza su texto, evalúa la calidad de la extracción y representa su estructura jurídica en una jerarquía legible por máquina. La Tarea 2, Segmentación de enunciados candidatos, divide los elementos con texto sustantivo en enunciados candidatos, preservando su ubicación, contexto estructural y vínculos con los elementos del documento. La Tarea 3, Clasificación de enunciados institucionales, utiliza un corpus etiquetado con validación humana y métodos de aprendizaje automático supervisado para clasificar cada candidato como enunciado regulativo, constitutivo o no institucional. Cada tarea produce resultados estructurados y trazables que sirven de insumo para la siguiente, manteniendo los vínculos con el documento original y los eventos intermedios de procesamiento. En conjunto, estas tareas establecen un flujo auditable desde los documentos fuente hasta los enunciados candidatos clasificados. Los enunciados clasificados proporcionan una base para el desarrollo futuro de un proceso más amplio de codificación con Gramática Institucional, incluida la extracción de componentes ABDICO.

Este documento debe entenderse como una propuesta de flujo de trabajo iterativo con participación humana. Los resultados automatizados se tratan como propuestas provisionales de procesamiento y codificación, y no como interpretaciones definitivas y autorizadas. La revisión humana se incorpora para evaluar la calidad de la extracción, validar clasificaciones ambiguas, refinar las reglas de análisis y codificación, mejorar los modelos computacionales y ampliar progresivamente un conjunto de datos validado para futuros procesos de entrenamiento y evaluación. Este proceso iterativo permite mejorar el flujo de trabajo a medida que se dispone de documentos adicionales y casos revisados manualmente, manteniendo la transparencia, la trazabilidad y la supervisión de los investigadores.

TAREA 1: PREPARACIÓN DEL TEXTO Y ESTRUCTURACIÓN DEL CORPUS

El propósito de esta tarea es transformar los documentos jurídicos o de políticas públicas originales en un corpus limpio, estructurado y trazable que pueda utilizarse en etapas posteriores de segmentación y clasificación de enunciados.

Subtarea 1.1: Incorporación de documentos e inventario del corpus

El primer paso consiste en crear un inventario estructurado de todos los documentos incluidos en el corpus, estableciendo la procedencia, jurisdicción jurídica, formato y características básicas de cada documento fuente antes de realizar cualquier extracción de texto o codificación automatizada.

Cada documento debe recibir un identificador único que permanezca inalterado durante todo el flujo de trabajo y vincule el archivo original con el texto extraído, la estructura jurídica, los enunciados candidatos, los resultados de clasificación, los registros de validación y las correcciones manuales. Para facilitar futuras auditorías, todos los archivos fuente, eventos de procesamiento, resultados generados, correcciones y versiones del analizador o del modelo deben conservarse mediante identificadores estables, rutas versionadas, marcas de tiempo y hashes de integridad, de modo que un revisor pueda rastrear qué insumo, versión del script, parámetros y artefacto intermedio produjo cada registro posterior sin sobrescribir ejecuciones anteriores.

El diccionario completo de campos del inventario documental y sus representaciones en SQLite y JSON se documentan en el documento complementario *Technical Database and Data-Structure Specification*.

El inventario documental resultante funcionará como la tabla de metadatos del corpus. Debe crearse antes de la extracción de texto y actualizarse únicamente cuando se incorporen, excluyan o corrijan documentos. Esta tabla proporciona la base para la trazabilidad y reproducibilidad de todas las etapas posteriores del flujo automatizado de Gramática Institucional.

Subtarea 1.2: Extracción de texto

Esta subtarea extrae el texto sin procesar del PDF fuente y lo almacena por página, preservando el documento original y creando una versión separada del texto sin procesar vinculada mediante `document_id`. El resultado aún no se interpreta, normaliza ni clasifica estructuralmente. Para los PDF con texto buscable, la extracción puede implementarse con `pdfplumber`. El resultado debe conservar los límites entre páginas y crear tanto un archivo de texto sin procesar como un archivo JSON organizado por página. En esta etapa, el flujo de trabajo no debe alterar ni corregir sustancialmente el texto; su objetivo es obtener la representación textual más completa posible, conservando el formato de origen y el procedimiento de extracción.

El método de extracción debe seleccionarse según el formato del archivo original registrado en el inventario documental. La siguiente tabla presenta ejemplos de métodos de extracción¹.

Formato del archivo original	Método de extracción	Instrucción del protocolo
PDF con texto buscable	Extracción directa de PDF a texto mediante <code>pdfplumber</code> .	Usar <code>pdfplumber</code> para extraer el texto página por página. Conservar el orden de las páginas y, cuando esté disponible, la información de disposición o posición.

¹ La vía de extracción implementada abarca los PDF con texto buscable mediante `pdfplumber`. Las vías de OCR y de documentos mixtos se conservan como opciones metodológicas, pero siguen siendo extensiones planificadas en esta versión.

Formato del archivo original	Método de extracción	Instrucción del protocolo
PDF escaneado	Reconocimiento óptico de caracteres (OCR).	Recomendado cuando el PDF contiene imágenes en lugar de una capa de texto accesible. La configuración del idioma del OCR debe coincidir con el idioma del corpus.
PDF mixto	Extracción directa del PDF seguida de OCR solo para las páginas cuyo texto falta o no es utilizable.	Aplicar primero pdfplumber. Identificar las páginas con extracción vacía, incompleta o corrupta y aplicar OCR únicamente a esas páginas.

La implementación debe priorizar el método menos invasivo que produzca texto utilizable. Se debe preferir la extracción directa cuando ya exista una capa de texto confiable. El OCR debe utilizarse solo cuando la extracción directa no esté disponible, sea incompleta o tenga calidad insuficiente.

Flujo de extracción

1. Identificar el formato del archivo original.
2. Seleccionar la vía de extracción.
3. Extraer el texto en el nivel estructural más pequeño disponible, preservando la fuente original.
 - En documentos PDF con texto buscable, el texto puede extraerse mediante pdfplumber, como en Turaga et al. (2025). La extracción debe producir un archivo de texto sin procesar que conserve los límites de página mediante marcadores explícitos, por ejemplo <PAGE number="17">. Este archivo de texto organizado por página constituye el resultado directo del proceso de extracción.
 - Para el procesamiento computacional y la trazabilidad, el texto extraído también debe almacenarse en un archivo JSON que contenga el identificador del documento, los metadatos de extracción y el texto sin procesar asociado a cada página. Se recomienda JSON en este protocolo porque permite conservar la relación entre el texto extraído y los metadatos pertinentes, incluidos el número de página, el identificador del documento, el método de extracción y la fecha de extracción. Esto es coherente con el uso de insumos JSON estructurados en DODFMiner (Guimarães et al., 2024).
4. Cada ejecución se registra como un evento de extracción vinculado a document_id. El evento registra el método, la herramienta y su versión, los recuentos de páginas, las rutas de salida, la información de integridad, el estado y las notas; su esquema completo se presenta en la especificación técnica.

Subtarea 1.3: Evaluación de la calidad de la extracción

Dado que los errores de OCR, los formatos documentales heterogéneos, las notas al pie, las referencias cruzadas y las tablas pueden introducir ruido en etapas posteriores de clasificación y extracción, esta subtarea evalúa si el proceso de extracción ha producido una representación técnicamente confiable del documento original.

Los problemas como encabezados repetidos, inconsistencias de espaciado, palabras divididas con guiones al final de línea y otros artefactos de formato se abordarán durante la normalización del texto. Sin embargo, las páginas de las que no se extrajo texto requieren una identificación

separada, porque pueden indicar una falla de extracción, una página basada en imágenes o la necesidad de aplicar OCR.

La evaluación puede ejecutarse en Python utilizando la salida JSON por página de la Subtarea 1.2. El procedimiento debe comparar los recuentos de páginas originales y extraídas, calcular la cantidad de texto extraído de cada página y marcar las páginas vacías o casi vacías. Produce un archivo JSON con control de calidad que conserva el texto original por página y añade indicadores de calidad específicos de cada página y un resumen de la extracción del documento.

La siguiente tabla presenta los controles técnicos automatizados aplicados en este proceso.

Control de calidad	Descripción	Salida
Comparación del número de páginas	Compara el número de páginas del documento original con el número de registros de página del archivo JSON extraído.	Marcar cuando los dos recuentos no coincidan.
Detección de páginas vacías	Identifica las páginas en que <code>raw_text</code> está vacío, es nulo o contiene solo espacios en blanco.	Marcar como <code>blank_extraction</code> .
Detección de páginas casi vacías	Identifica páginas con muy poco texto extraído, según un mínimo predefinido de caracteres distintos de espacios.	Marcar como <code>near_blank_extraction</code> .

Las páginas marcadas para revisión manual deben incluir tanto un código de motivo legible por máquina como una nota de texto libre que explique la razón de la revisión. Esto permite a los revisores posteriores distinguir entre extracción vacía, extracción casi vacía, problemas de codificación, discrepancias en el número de páginas y contenido no textual complejo, como tablas, figuras, firmas o material escaneado.

Una extracción vacía o casi vacía no debe interpretarse automáticamente como una página fuente vacía. El documento original puede contener una página escaneada, una tabla basada en imágenes, una figura, una firma u otro elemento complejo del que la extracción de texto estándar no pueda recuperar texto. Por ello, estas páginas deben marcarse para su posterior inspección, aplicación de OCR o conservación como contenido no textual.

Subtarea 1.4: Normalización del texto

El propósito de la normalización del texto es reducir el ruido técnico introducido por la extracción de PDF, el reconocimiento óptico de caracteres (OCR), los formatos documentales heterogéneos y los repositorios fuente, preservando el texto original extraído. Esta subtarea recibe el JSON por página con control de calidad producido en la Subtarea 1.3, conserva el campo `raw_text` original sin modificarlo y aplica todas las transformaciones de normalización a un campo `normalized_text` separado. El texto limpio resultante puede utilizarse para identificar la estructura jurídica y segmentar enunciados candidatos, manteniendo la trazabilidad respecto de la extracción original.

1.4.1. Normalización de caracteres y codificación

El primer paso debe estandarizar la representación de los caracteres del texto. Esto incluye aplicar normalización Unicode, corregir artefactos irregulares de codificación, estandarizar comillas y guiones, y eliminar caracteres especiales no lingüísticos cuando sean claramente ruido técnico. Puede implementarse en Python mediante `unicodedata` y expresiones regulares, manteniendo un procedimiento transparente, reproducible y fácil de documentar (Galik & Johnson, 2026; Saketos et al., 2024).

En los textos jurídicos en español, las tildes deben conservarse en el texto normalizado principal. No deben eliminarse por defecto, porque los signos diacríticos pueden ser relevantes para los

nombres, los términos jurídicos y la legibilidad. Si posteriormente se requiere una comparación que no distinga tildes, el protocolo puede crear un campo auxiliar, pero el campo `normalized_text` principal debe conservarlas.

La siguiente tabla ilustra los tipos de normalización de caracteres y codificación que pueden aplicarse en este paso.

Proceso de normalización	Ejemplo en el texto extraído	Resultado normalizado	Propósito
Normalización de composición Unicode (NFC)	resolucio\u0301n	resolución	Convierte los caracteres descompuestos a una forma compuesta estándar. Se recomienda para el campo principal <code>normalized_text</code> .
Normalización de compatibilidad Unicode	fiscalización	fiscalización	Convierte los caracteres de compatibilidad, como las ligaduras, en caracteres estándar. Es útil cuando la extracción del PDF produce variantes tipográficas.
Estandarización de comillas	"El Ministerio" / 'autoridad'	"El Ministerio" / 'autoridad'	Estandariza las comillas tipográficas como comillas simples o dobles rectas para facilitar las coincidencias.
Estandarización de guiones	Ambiente —en adelante—	Ambiente -en adelante-	Convierte las rayas o semirrayas en un formato de guion uniforme.
Normalización de espacios	Artículo 17	Artículo 17	Convierte los espacios de no separación o irregulares en espacios normales.
Eliminación de guiones opcionales	descontaminación	descontaminación	Elimina las marcas de división de palabras invisibles introducidas por la extracción del PDF.
Detección del carácter de sustitución	regulaci□n	marcado para revisión	El carácter □ suele indicar un problema de codificación. Debe marcarse para revisión en lugar de corregirse automáticamente.
Eliminación de caracteres de ancho cero	Ministerio	Ministerio	Elimina caracteres invisibles que pueden interferir con la tokenización o la búsqueda de coincidencias.
Versión auxiliar sin distinción de tildes	Secretaría deberá informar la resolución	secretaria debera informar la resolucion	Debe almacenarse únicamente en un campo auxiliar, como <code>matching_text</code> , y no en el campo principal <code>normalized_text</code> .

1.4.2. Limpieza de espacios, saltos de línea y división de palabras

El segundo paso debe corregir los artefactos de formato generados durante la extracción de texto. Esto incluye eliminar espacios excesivos, estandarizar los saltos de línea, reducir las líneas en blanco repetidas y unir las palabras divididas incorrectamente por guiones al final de una línea.

Esta operación debe aplicarse con cuidado. No deben eliminarse todos los saltos de línea, porque algunos pueden indicar estructura jurídica, como artículos, párrafos, listas numeradas, incisos con letras o encabezados. Por lo tanto, los marcadores estructurales como Artículo, CAPÍTULO,

los encabezados de sección, los elementos numerados y los elementos con letras deben conservarse siempre que aparezcan en el texto.

1.4.3. Eliminación de contenido técnico no sustantivo

El tercer paso debe eliminar el contenido técnico o generado por el repositorio que no forma parte del propio documento jurídico. Esto puede incluir etiquetas HTML, elementos de navegación web, etiquetas repetidas del repositorio, números de página generados automáticamente o encabezados y pies de página duplicados.

Sin embargo, la implementación no debe eliminar automáticamente el contenido con significado jurídico. Los títulos, capítulos, secciones, encabezados de artículos, definiciones, considerandos, anexos, notas al pie y tablas pueden aportar contexto para la posterior identificación de la estructura jurídica y la codificación mediante Gramática Institucional.

Por lo tanto, se recomienda una eliminación selectiva:

Tipo de contenido	Tratamiento recomendado
Etiquetas HTML/XML	Eliminar de <code>normalized_text</code> .
Encabezados y pies de página del repositorio	Eliminar cuando sean artefactos técnicos repetidos.
Números de página generados por el repositorio	Eliminar o almacenar por separado.
Título del documento jurídico	Conservar.
Encabezados de capítulos, secciones y artículos	Conservar.
Definiciones	Conservar para su posterior clasificación.
Tablas, figuras, anexos y notas al pie	Conservar o marcar para su representación estructural.

1.4.4. Resultado del paso de normalización


El resultado de esta subtask debe ser un archivo JSON normalizado a nivel de página. El archivo debe conservar el `raw_text` original de la subtask 1.2 y las marcas de calidad de la subtask 1.3, y agregar un nuevo campo `normalized_text`. Los metadatos a nivel de documento también deben registrar las reglas de normalización aplicadas, el software utilizado, la fecha de procesamiento y cualquier advertencia.

Subtask 1.5: Identificación de la estructura jurídica y representación jerárquica

El propósito de esta subtask es generar una representación jerárquica del documento jurídico a partir del corpus normalizado a nivel de página producido en la subtask 1.4, preservando la organización formal del texto jurídico en una estructura legible por máquina.

La implementación actual utiliza un analizador basado en reglas para procesar el JSON normalizado a nivel de página creado en la subtask 1.4. El campo de texto principal para identificar la estructura es `normalization.normalized_text`. El campo `raw_text` se conserva para mantener la trazabilidad, pero no se utiliza como fuente principal del análisis. Cada elemento estructural conserva información suficiente para rastrearlo hasta el documento fuente y reconstruir la jerarquía jurídica.

El analizador no infiere la jerarquía a partir del significado semántico. Utiliza el contexto estructural explícito más reciente. Por ejemplo, un párrafo que sigue al Artículo 57 se anida bajo ese artículo, mientras que un artículo que sigue a VI.6.1 se anida bajo ese encabezado numerado. El siguiente esquema muestra la organización jerárquica del documento en el archivo JSON:



El analizador sigue la siguiente secuencia de procesos:

1. **Conversión de páginas en líneas:** Lee cada página normalizada y la convierte en líneas candidatas ordenadas. Se conservan los números de página para que cada elemento estructural pueda mantener `page_start` y `page_end`.
2. **Separación de marcadores insertos en líneas:** Algunos marcadores jurídicos pueden aparecer dentro de una línea en lugar de al inicio debido a la extracción del PDF o a la normalización. El analizador puede separar marcadores de preámbulo insertos, como Visto:,

Considerando: o Decreto:, para convertirlos en puntos de referencia estructurales independientes.

3. **Detección del bloque de metadatos:** Los campos de metadatos de tipo LeyChile se detectan al inicio del documento y se anidan bajo un metadata_block. Algunos ejemplos son Tipo Norma, Fecha Publicación, Organismo, Título, Id Norma y URL.
4. **Detección del preámbulo:** Las etiquetas de preámbulo, como Visto, Considerando, Decreto y Resuelvo, se identifican como elementos de preámbulo. Su texto se almacena como párrafos hijos.
5. **Detección de la jerarquía jurídica principal:** Los capítulos, secciones, subsecciones, párrafos como encabezados, encabezados con numeración romana-decimal, artículos y artículos transitorios se identifican mediante marcadores explícitos.
6. **Detección de contenido en los niveles terminales:** Los párrafos, elementos numerados, elementos con letras, elementos con números romanos, elementos compuestos, elementos con viñetas, objetos visuales, notas de fuente, notas de objeto y firmas se almacenan como elementos terminales o de niveles inferiores.
7. **Asignación del elemento padre:** Cada elemento se anida bajo el contexto jurídico actual. Al asignar elementos padre, el analizador prioriza los estados de artículo, encabezado numerado activo, subsección, sección, capítulo y preámbulo.
8. **Generación de resultados:** Después de analizar todas las páginas, se finalizan los rangos de elementos abiertos, se actualizan los rangos de páginas y se escriben las salidas anidadas y planas.

El analizador reconoce elementos estructurales solo cuando están marcados explícitamente en el texto normalizado. La siguiente tabla resume los principales tipos de elementos y las reglas utilizadas para identificarlos en la versión estable actual.

Tipo de elemento	Marcadores / regla	Notas sobre la decisión
metadata_block / metadata_field	Tipo Norma:, Fecha Publicación:, Fecha Promulgación:, Organismo:, Título:, Tipo Versión:, Inicio Vigencia:, Id Norma:, URL:	Se utiliza principalmente para metadatos de tipo LeyChile. Los campos de metadatos se anidan bajo un único metadata_block.
preamble	Visto:, Considerando:, Decreto:, Resuelvo:	Se detectan como etiquetas explícitas de preámbulo. El texto que sigue a estas etiquetas se almacena como párrafos hijos.
chapter	CAPÍTULO + etiqueta romana o numérica	La etiqueta se conserva como CAPÍTULO I, CAPÍTULO II, etc. El título se separa cuando está presente.
title / section / subsection	TÍTULO, SECCIÓN, SUBSECCIÓN, PÁRRAFO + etiqueta romana o numérica	Se utilizan cuando están presentes explícitamente. Los títulos se limpian únicamente para eliminar los separadores iniciales.
numbered_heading	Encabezado romano-decimal, como I.1, I.2.1, III.3, VI.6, VI.6.1	Se utiliza una pila de encabezados numerados para representar su profundidad de anidación.
article	Artículo + número, seguido de puntuación/separador o fin de línea	Esto evita tratar referencias en el texto, como “artículo 43 del presente decreto”, como nuevos encabezados de artículo.

Tipo de elemento	Marcadores / regla	Notas sobre la decisión
transitory_article	Artículo Transitorio, Artículo único Transitorio o artículo transitorio ordinal	Se almacena por separado de los artículos numerados ordinarios.
numbered_item	1. texto del elemento o 1) texto del elemento	Se excluyen los años de cuatro dígitos, como 2016., para evitar falsos elementos de lista.
compound_item	a.1), a.2), b.1), etc.	Se utiliza para marcadores de lista anidados alfabético-decimales.
lettered_item	a) texto del elemento o a. texto del elemento	En la versión v0.6 solo se utilizan formas con puntuación explícita. Las letras sin puntuación se dejan intencionalmente para versiones futuras.
roman_item	i), i., ii), ii., iii), iii., etc.	Se utiliza para elementos de lista con números romanos en minúsculas.
bullet_item	- texto del elemento, – texto del elemento, — texto del elemento	Se utiliza para elementos de lista marcados con guiones.
table / graph / figure / annex	Tabla, Cuadro, Gráfico, Figura o Anexo seguido de una etiqueta compacta y luego : o .	El requisito de puntuación impide que las referencias a tablas o gráficos en el texto se clasifiquen como nuevos objetos visuales.
source_note	Fuente:	Se anida bajo la tabla, gráfico o figura más reciente, cuando existe.
object_note	PI=, CI=, (*), (**), Nota:, Observación	Se anida bajo el objeto visual más reciente, cuando existe.
lettered_heading	A. Texto del encabezado, B. Texto del encabezado	Se utiliza para subencabezados internos en mayúsculas, especialmente en los capítulos posteriores.
signature_block	Anótese, Tómese razón, Publíquese, Comuníquese, Regístrese	Se utiliza para el contenido de cierre relativo a firmas y promulgación.
paragraph	Unidad textual predeterminada bajo el elemento padre actual	Se utiliza cuando el texto no coincide con otro marcador estructural explícito.
other	Opción de respaldo cuando no hay un elemento padre o una estructura clara	Se le asigna un nivel de confianza incierto.

La asignación del elemento padre se basa en el contexto jurídico actual. El analizador utiliza una jerarquía de estados en lugar de inferencia semántica. Cuando se detecta un nuevo elemento estructural, se vincula al elemento padre activo más específico disponible.

Regla	Decisión sobre el elemento padre
Elementos del nivel raíz	metadata_block, los bloques de preámbulo, los capítulos y algunos bloques de firmas pueden aparecer en el nivel raíz.
Capítulos	Un capítulo se convierte en el elemento padre activo de nivel superior. Las nuevas secciones, los encabezados numerados y los artículos se vinculan bajo él hasta que aparece un nuevo capítulo.

Regla	Decisión sobre el elemento padre
Encabezados numerados	Los encabezados romano-decimales se anidan según su profundidad. Por ejemplo, I.2.1 se anida bajo I.2; VI.6.1 se anida bajo VI.6.
Artículos bajo encabezados	Si hay un encabezado numerado activo, un nuevo artículo se vincula bajo ese encabezado en lugar de directamente bajo el capítulo.
Artículos sin encabezado numerado activo	El artículo se vincula bajo la subsección, sección o capítulo actual.
Párrafos y elementos	Los párrafos y los elementos de lista se vinculan bajo el artículo actual cuando hay un artículo activo; de lo contrario, se vinculan bajo el encabezado o capítulo activo.
Objetos visuales	Las tablas, los gráficos y las figuras se vinculan bajo el elemento padre actual. Sus notas y fuentes se anidan bajo el objeto visual.
Anexos	Los anexos se vinculan bajo el capítulo actual cuando esta relación es clara.
Bloque de firmas	Las fórmulas de cierre de firma inician un <code>signature_block</code> y las líneas de firma posteriores pueden agregarse a él.

Las etiquetas y los títulos se almacenan por separado. Para los encabezados estructurales y los objetos visuales, el analizador conserva la etiqueta visible y almacena el título o leyenda por separado cuando están disponibles. Se eliminan del título los separadores iniciales, como :, - o ., pero no se reescribe su redacción. Los determinantes, contracciones, preposiciones, conjunciones, conectores y comienzos de oración reflexivos o jurídicos en español con mayúscula inicial pueden actuar como marcadores conservadores del límite del título; la lista exacta implementada se documenta en la especificación técnica.

La regla distingue entre mayúsculas y minúsculas. Las palabras funcionales en minúsculas, como para, con, de, en o si, no se utilizan como límites de títulos porque aparecen con frecuencia dentro de encabezados y leyendas jurídicos válidos.

El analizador actual solo identifica leyendas de tablas, gráficos, figuras y anexos cuando la etiqueta es compacta y está seguida de dos puntos o un punto. Esto evita que las referencias en el texto corriente se conviertan en falsos objetos visuales. Las líneas Fuente: se almacenan como elementos `source_note`. Cuando se ha detectado una tabla, gráfico o figura reciente, la `source_note` se anida bajo ese objeto visual. Si una línea Fuente absorbe accidentalmente la siguiente oración del cuerpo del texto, se utiliza la misma regla de límite basada en palabras funcionales en español con mayúscula inicial para separar el texto de la fuente del párrafo siguiente.² Cuando un párrafo o elemento de lista se divide únicamente debido a un salto de página, el siguiente elemento de texto se agrega al anterior si comienza con una letra minúscula y aparece en una página posterior.

La subtask 1.5 produce dos tablas de base de datos complementarias. La primera, `structure_events`, registra cada ejecución del analizador de estructura jurídica. Vincula la salida estructurada con el documento original, el evento de extracción, el evento de evaluación de calidad y el evento de normalización. También registra la herramienta, el método y la versión del analizador, el campo de texto de entrada, las rutas de los archivos de salida, la cantidad de elementos, la cantidad de advertencias y el estado de ejecución. Esta tabla permite la reproducibilidad al hacer posible identificar qué versión del analizador generó cada representación de la estructura jurídica.

² Las notas como PI=, CI=, (*), (**), Nota: y Observación se almacenan como elementos `object_note` cuando aparecen en el contexto de un objeto visual reciente.

La tabla `structure_elements` almacena una representación plana del JSON jerárquico generado en la subtarea 1.5. Cada fila corresponde a un elemento estructural, como un capítulo, artículo, párrafo, elemento numerado, tabla, gráfico, nota de fuente o bloque de firmas. Las variables `element_id` y `parent_id` conservan la relación entre padre e hijo, mientras que `element_order` conserva el orden original del documento y `nesting_level` registra la profundidad del elemento dentro de la jerarquía.

En conjunto, `structure_events` y `structure_elements` mantienen la trazabilidad desde el texto normalizado de entrada hasta las salidas estructuradas en JSON y CSV. Sus campos SQL implementados, relaciones de claves foráneas, valores categóricos y ejemplos se documentan en la especificación técnica complementaria.

TAREA 2: SEGMENTACIÓN EN ENUNCIADOS CANDIDATOS

El propósito de esta tarea es transformar el corpus jurídico estructurado producido en la tarea 1 en unidades a nivel de oración que puedan utilizarse en las etapas posteriores de clasificación de enunciados. Su propósito se limita a producir unidades textuales candidatas trazables.

Un enunciado candidato se define aquí como una unidad textual a nivel de oración extraída de un elemento estructural sustantivo del documento jurídico. Estos enunciados candidatos aún no son enunciados institucionales confirmados. Son unidades provisionales que posteriormente pueden clasificarse como regulativas, constitutivas o no institucionales en el contexto de la codificación mediante Gramática Institucional.

La tarea recibe como entrada la representación completa de la estructura jurídica generada en la subtarea 1.5, principalmente `structure_elements` y su JSON jerárquico correspondiente, en lugar del PDF original o del texto bruto de las páginas. La segmentación se aplica de manera independiente a los elementos sustantivos que contienen texto —párrafos, elementos numerados, elementos con letras, elementos compuestos, elementos con números romanos y elementos con viñetas—, mientras que los metadatos, encabezados, tablas, gráficos, figuras, notas de fuente, notas de objeto y material de firmas se conservan como estructura contextual y no se segmentan como enunciados. Esto mantiene cada candidato vinculado con su `element_id`, `parent_id`, tipo de elemento, orden, rango de páginas, marcas de revisión y metadatos de origen.

Subtarea 2.1: Método de segmentación

La implementación actual utiliza un procedimiento de segmentación de oraciones en español basado en spaCy. El modelo predeterminado es `es_core_news_md`. Este modelo se utiliza porque el corpus está en español y los límites de las oraciones dependen de la puntuación, las abreviaturas y las convenciones sintácticas del español. spaCy produce límites iniciales de oración, que luego se revisan mediante las reglas deterministas de texto jurídico descritas en la siguiente subtarea. El posprocesamiento es necesario porque la segmentación general de oraciones puede dividir incorrectamente referencias jurídicas en español, abreviaturas, marcadores numerados, referencias a decretos o texto que sigue a puntos y coma o dos puntos.

Subtarea 2.2: Posprocesamiento de límites en textos jurídicos

Después de que spaCy genera límites preliminares de oración, la implementación aplica reglas conservadoras de posprocesamiento para evitar divisiones falsas. El propósito de estas reglas es proteger los límites que resultan técnicamente inseguros para los documentos jurídicos en español.

Se protegen los siguientes casos de límites:

Caso de límite	Decisión
Punto y coma o dos puntos	No tratar el límite como una división definitiva de oración cuando el texto siguiente continúa la misma unidad jurídica.
Salto de línea no terminal	Unir cuando el lado izquierdo no termina con puntuación de fin de oración.
Continuación tras puntos suspensivos	Unir cuando a los puntos suspensivos les sigue una continuación en minúscula.
Abreviaturas de artículo	Proteger abreviaturas como Art. y Arts. cuando están seguidas de una referencia jurídica.
Abreviaturas de decretos	Proteger expresiones como D.S., D.L. y D.F.L.
Abreviaturas de número	Proteger expresiones como N°, N°, Núm. y No.

Caso de límite	Decisión
Tratamientos personales	Proteger expresiones como Sr. y Sra.
Abreviatura etc.	Evitar la división cuando etc. está seguido de texto de continuación.
Iniciales y abreviaturas con varios puntos	Evitar tratar las iniciales o abreviaturas con varios puntos como finales de oración.
Marcadores jurídicos numerados	Evitar tratar marcadores aislados como 1. o 2) como oraciones independientes.
Expresiones numéricas	Evitar la división dentro de números decimales, expresiones numéricas con puntos o patrones similares.

Estas reglas son deliberadamente conservadoras. Solo unen segmentos cuando existe una razón técnica clara para considerar que la división es insegura.

Subtarea 2.3: Creación de enunciados candidatos

Para cada elemento fuente elegible, el procedimiento de segmentación crea uno o más enunciados candidatos. Cada enunciado candidato recibe un identificador estable y conserva su relación con la estructura jurídica original.

El enunciado candidato conserva:

Campo	Propósito
statement_id	Identificador estable asignado a cada enunciado candidato.
segmentation_id	Identificador de la ejecución de segmentación que produjo el enunciado.
document_id	Identificador del documento fuente.
structure_id	Evento de estructura jurídica utilizado como entrada.
source_element_id	Elemento estructural del cual se extrajo el enunciado.
source_parent_id	Elemento padre del elemento fuente.
source_element_type	Tipo de elemento fuente, como párrafo o elemento numerado.
source_element_order	Orden original del elemento fuente en la estructura jurídica.
sentence_order_within_element	Posición de la oración dentro del elemento fuente.
statement_order	Orden global del enunciado candidato en el documento.
statement_text	Texto del enunciado candidato.
source_char_start / source_char_end	Posiciones de caracteres en el element_text original.
page_start / page_end	Rango de páginas heredado del elemento estructural fuente.
page_assignment_method	Método utilizado para asignar la ubicación de página.
segmentation_method	Método utilizado para crear el enunciado candidato.
segmentation_status	Estado del enunciado candidato individual.
requires_manual_review	Indica si el candidato debe revisarse manualmente.
review_reason_code	Motivo de revisión legible por máquina.
review_reason_note	Explicación en texto libre de la marca de revisión.

Subtarea 2.4: Marcas de revisión y advertencias de segmentación

El procedimiento de segmentación no descarta automáticamente los enunciados candidatos inciertos. En cambio, los marca para revisión manual. Esto es coherente con la lógica general de participación humana del protocolo, en la que las salidas automatizadas se tratan como propuestas iniciales de codificación que pueden revisarse y perfeccionarse.

Un enunciado candidato puede marcarse para revisión cuando:

Código del motivo de revisión	Significado
very_short_sentence	El candidato tiene menos de 20 caracteres o menos de tres tokens de tipo palabra.
sentence_starts_lowercase	El candidato comienza con una letra minúscula, lo que puede indicar una continuación dividida en exceso.
possible_abbreviation_split	El límite aceptado sigue a una abreviatura conocida y puede requerir revisión.
missing_terminal_punctuation	El candidato carece de puntuación de fin de oración. Esto puede ser aceptable en elementos de lista, pero debe comprobarse.
source_element_review:<code>	El candidato hereda una marca de revisión manual del elemento estructural fuente.

Subtarea 2.5: Archivos de salida y registros de base de datos

La tarea 2 produce tres resultados principales.

1. Archivo JSON que contiene metadatos del documento, metadatos del evento de estructura, metadatos de segmentación, controles de calidad, resúmenes de advertencias, uniones de segmentos por límites protegidos y la lista completa de enunciados candidatos.
2. Archivo CSV con una fila por enunciado candidato. Este archivo está diseñado para la inspección, la revisión manual y la comparación sencilla entre ejecuciones de segmentación.
3. Resultados en SQLite mediante dos tablas: la tarea 2 registra un registro `segmentation_events` por ejecución y un registro `candidate_statements` por oración aceptada. El evento conserva la entrada de estructura, el modelo y las versiones de spaCy, los recuentos, las rutas de salida, el estado y las notas; las filas de candidatos conservan la procedencia del elemento fuente, el orden, el rango de páginas, las posiciones de caracteres, el método de segmentación y las marcas de revisión.

TAREA 3: CLASIFICACIÓN DE ENUNCIADOS CANDIDATOS

El propósito de esta tarea es clasificar los enunciados candidatos producidos en la tarea 2 según su relevancia y tipo institucional. Cada enunciado candidato se asigna a una de tres categorías mutuamente excluyentes: regulativo, constitutivo o no institucional.

Los enunciados regulativos prescriben, permiten, prohíben, autorizan o regulan de otra manera las acciones o decisiones de un actor. Los enunciados constitutivos definen o establecen entidades, roles, propiedades, funciones o arreglos institucionales. Los enunciados no institucionales contienen información descriptiva, contextual, probatoria, fragmentaria o de otro tipo que no constituye un enunciado institucional ABDICO.

La tarea recibe como entrada principal la tabla `candidate_statements` producida en la tarea 2 y un corpus etiquetado validado por personas que contiene ejemplos de las tres categorías de clasificación. Cada candidato conserva el texto original del enunciado, su identificador estable, el elemento estructural fuente, el identificador del documento, la ubicación de página y el contexto jurídico. Por lo tanto, la clasificación agrega una nueva capa analítica sin modificar el enunciado candidato ni romper su conexión con el documento fuente.

La implementación actual utiliza aprendizaje automático supervisado con representación de frecuencia de término–frecuencia inversa de documento (TF-IDF). Este enfoque se basa en Wróblewska et al. (2023), quienes utilizan características textuales y clasificación supervisada para distinguir entre enunciados institucionales regulativos y constitutivos. El presente protocolo amplía el problema de clasificación al agregar una categoría no institucional, lo que permite al modelo distinguir los enunciados institucionales codificables de otras unidades textuales generadas durante la segmentación de oraciones.

Subtarea 3.1: Conjunto de datos de entrada

La tarea 3 recibe dos conjuntos de datos de entrada separados, pero estructuralmente compatibles. El primero es un **corpus etiquetado validado por personas**, utilizado para entrenar y evaluar el modelo. El segundo es un **corpus de clasificación no etiquetado**, que contiene los enunciados candidatos generados en la tarea 2 a los que se aplicará el modelo entrenado.

Corpus etiquetado validado por personas

El corpus etiquetado proporciona las observaciones de referencia necesarias para desarrollar y evaluar el modelo de clasificación supervisada. Cada observación contiene un enunciado candidato original y una clasificación validada por personas como `regulative`, `constitutive` o `non_institutional`. Posteriormente, este corpus se divide en particiones de entrenamiento y prueba, como se describe en la subtarea 3.2.

Para la implementación actual, el corpus etiquetado se construyó alineando los enunciados candidatos generados en la tarea 2 con un conjunto de datos existente codificado manualmente y revisando de forma manual las correspondencias resultantes. Los enunciados candidatos para los que no se encontró una correspondencia no se clasificaron automáticamente como no institucionales. Solo se incorporó una etiqueta al corpus de modelado cuando podía sustentarse en el conjunto de datos codificado existente o en una validación humana explícita. El procedimiento detallado de búsqueda de correspondencias, alineación y revisión se documenta por separado en el proyecto de GitHub³.

³ https://github.com/dlatorocabrera/IG_protocol_project.git

Como mínimo, cada observación del corpus etiquetado debe contener la siguiente información:

Campo	Propósito
statement_id	Identificador estable del enunciado candidato generado en la tarea 2.
statement_text	Texto original del enunciado candidato utilizado como base para la clasificación.
class_label	Clasificación validada por personas: regulative, constitutive o non_institutional.
document_id	Identificador del documento fuente.
segmentation_id	Identificador del evento de segmentación de la tarea 2 que generó el enunciado candidato.
source_element_id	Identificador del elemento estructural del cual se extrajo el enunciado.
source_element_type	Tipo de elemento fuente, como paragraph, numbered_item o lettered_item.
duplicate_group_id	Identificador utilizado para mantener juntos los duplicados exactos o de texto normalizado durante la partición del conjunto de datos.
label_source	Procedencia de la clasificación validada, como un conjunto de datos existente codificado manualmente o una revisión humana posterior.
dataset_version	Versión del corpus etiquetado en la que se incluye la observación.

Corpus de clasificación no etiquetado

El corpus de clasificación no etiquetado contiene los enunciados candidatos producidos en la tarea 2 para los que se requiere una clasificación institucional. Estas observaciones conservan el texto original del enunciado y sus vínculos con el documento fuente, el evento de segmentación y el elemento de estructura jurídica, pero no requieren un **class_label** validado por personas. Después del desarrollo y la evaluación del modelo, el modelo seleccionado se aplica a este corpus para generar las clasificaciones predichas y la información de confianza asociada.

Como mínimo, cada observación del corpus de clasificación no etiquetado debe contener la siguiente información:

Campo	Propósito
statement_id	Identificador estable del enunciado candidato generado en la tarea 2.
statement_text	Texto original del enunciado candidato enviado al modelo de clasificación.
document_id	Identificador del documento fuente.
segmentation_id	Identificador del evento de segmentación de la tarea 2 que generó el enunciado candidato.
source_element_id	Identificador del elemento estructural del cual se extrajo el enunciado.
source_element_type	Tipo de elemento fuente a partir del cual se generó el enunciado candidato.
dataset_version	Versión del corpus de enunciados candidatos enviado para clasificación.

En ambos conjuntos de datos de entrada, el **statement_text** original debe permanecer sin cambios. Pueden crearse representaciones normalizadas o simplificadas para detectar duplicados, alinear, generar características o procesar el modelo, pero deben almacenarse por separado y nunca reemplazar el texto original del candidato. Del mismo modo, las predicciones

del modelo deben almacenarse por separado de `class_label`, para garantizar que las etiquetas validadas por personas y las clasificaciones automatizadas sigan siendo distinguibles y trazables de forma independiente.

Subtarea 3.2: Partición del conjunto de datos

El corpus etiquetado debe dividirse en particiones separadas antes de la vectorización del texto, la selección de características o el entrenamiento del modelo. El propósito de esta separación es garantizar que el desarrollo y la evaluación del modelo se realicen sobre observaciones diferentes y reducir el riesgo de filtración de información. Esto sigue el enfoque general de clasificación supervisada utilizado por Wróblewska et al. (2023), en el que el desempeño del modelo se evalúa con datos que no se utilizaron para ajustar el clasificador.

La implementación actual utiliza una partición estratificada 80/20:

- El 80% de las observaciones se asigna a la partición de entrenamiento.
- El 20% se asigna a una partición de prueba.
- La distribución de enunciados regulativos, constitutivos y no institucionales se conserva lo más fielmente posible en ambas particiones.
- Debe utilizarse una semilla aleatoria fija para que la partición pueda reproducirse.

Antes de asignar las observaciones a las particiones, deben identificarse los duplicados exactos y de texto normalizado. Los enunciados que pertenecen al mismo grupo de duplicados deben asignarse a la misma partición. Esto evita que un clasificador se entrene y evalúe con observaciones idénticas o funcionalmente equivalentes.

El procedimiento de partición debe seguir esta secuencia:

1. Confirmar que cada observación elegible tiene un `statement_id` estable, un `statement_text` original y una etiqueta de clase validada por personas.
2. Excluir o dejar en espera las observaciones con etiquetas sin resolver o sin identificadores de enunciados candidatos.
3. Identificar los grupos de duplicados exactos y de texto normalizado.
4. Aplicar una partición estratificada basada en las tres etiquetas de clasificación.
5. Asignar todos los miembros de un grupo de duplicados a la misma partición.
6. Verificar las distribuciones de clases resultantes y confirmar que ningún grupo de duplicados aparece en ambas particiones.
7. Almacenar las asignaciones a particiones y los parámetros utilizados para generarlas.

La partición de prueba debe quedar excluida del ajuste del vectorizador, la selección de características, la validación cruzada y el entrenamiento del modelo. Puede utilizarse después del desarrollo interno del modelo para comparar configuraciones candidatas. Dado que la partición de prueba actual contribuyó a la selección del modelo prototipo, no debe interpretarse como un conjunto de prueba independiente final. Por lo tanto, una evaluación posterior debe aplicar el flujo de trabajo fijado a un corpus completamente nuevo que no haya contribuido a la búsqueda de correspondencias, el etiquetado, la comparación de modelos o la selección del prototipo.

El proceso de partición crea dos registros de base de datos relacionados:

1. `split_events`: conserva la versión del conjunto de datos, las entradas de revisión de la fuente, la información de elegibilidad y clases, los parámetros de partición, los controles de duplicados y calidad, las rutas y los hashes de salida, el estado de ejecución, la marca temporal y las notas.

2. `split_assignments`: conserva el identificador de partición, el identificador del candidato, el identificador del grupo de duplicados, la etiqueta de referencia validada por personas, la partición asignada, la semilla aleatoria y la marca temporal de creación. Los diccionarios completos de campos y los valores aceptados para ambas tablas se presentan en la especificación técnica complementaria.

Una vez creadas y utilizadas para el desarrollo del modelo, las asignaciones a particiones deben permanecer sin cambios. Cualquier modificación posterior al conjunto de datos etiquetado debe generar una nueva versión del conjunto de datos y, cuando corresponda, un nuevo evento de partición.

Subtarea 3.3: Representación textual mediante TF-IDF

Después de la partición, los enunciados candidatos deben transformarse en representaciones numéricas que puedan procesarse mediante modelos de aprendizaje automático supervisado. La implementación actual utiliza frecuencia de término–frecuencia inversa de documento (TF-IDF) para representar el contenido léxico de cada enunciado candidato.

TF-IDF asigna mayor peso a los términos y expresiones que son informativos dentro del corpus, mientras reduce la influencia de los términos que aparecen con frecuencia en muchos enunciados. Esta representación es adecuada para la tarea de clasificación actual porque los enunciados regulativos, constitutivos y no institucionales pueden diferir en su uso de verbos, expresiones modales, actores institucionales, conceptos jurídicos y combinaciones recurrentes de palabras.

El vectorizador TF-IDF debe ajustarse exclusivamente con la partición de entrenamiento. Luego, el vectorizador ajustado se aplica sin cambios a la partición de prueba. En consecuencia, los enunciados de la partición de prueba no contribuyen a la creación del vocabulario, los cálculos de frecuencia de documento, los pesos de frecuencia inversa de documento ni ningún otro parámetro ajustado del vectorizador.

La implementación actual aplica las siguientes decisiones de vectorización:

Decisión de vectorización	Implementación
Unidad de entrada	Un enunciado candidato por observación.
Texto fuente	<code>statement_text</code> original generado en la tarea 2.
Analizador	Análisis basado en palabras.
Rango de n-gramas	Unigramas, bigramas y trigramas.
Mayúsculas y minúsculas	El texto se convierte a minúsculas para la vectorización.
Tildes	Se conservan.
Palabras vacías	Se conservan.
Palabras de un carácter en español	Se conservan a, e, o, u e y.
Reducción a la raíz	No se aplica.
Lematización	No se aplica.
Ponderación	Frecuencia de término–frecuencia inversa de documento.
Normalización	Normalización L2.
Frecuencia inversa de documento	IDF suavizada.

La conservación de las palabras vacías es intencional. Las palabras funcionales en español pueden formar parte de expresiones deónticas, construcciones institucionales o patrones léxicos recurrentes que contribuyen a distinguir entre clases de enunciados. Del mismo modo, se conservan las tildes porque forman parte de la ortografía original del español y pueden distinguir palabras que de otro modo serían similares.

Los unigramas representan palabras individuales, mientras que los bigramas y trigramas representan secuencias de dos o tres palabras consecutivas. La inclusión de estos n-gramas permite al modelo utilizar tanto términos léxicos aislados como expresiones breves de varias palabras. Por ejemplo, las expresiones asociadas con obligaciones, permisos, definiciones, actores institucionales o condiciones jurídicas pueden ser más informativas cuando se representan como combinaciones de palabras que como tokens independientes.

El proceso de vectorización debe seguir esta secuencia:

1. Ajuste: cargar los identificadores de enunciados, el texto original, las etiquetas validadas y las asignaciones a particiones creadas en la subtask 3.2; ajustar el vocabulario y los pesos TF-IDF utilizando únicamente los enunciados de entrenamiento.
2. Transformación: transformar los enunciados de entrenamiento y aplicar el mismo vectorizador ajustado, sin volver a ajustarlo, a los enunciados de prueba.
3. Validación: verificar las dimensiones de las matrices, los valores no nulos, el orden de las filas, los identificadores de enunciados, la pertenencia a particiones y la ausencia de información de vocabulario derivada de los datos de prueba.
4. Registro de artefactos: almacenar el vectorizador ajustado, las matrices dispersas, el índice de características, las correspondencias de filas, los parámetros, los resultados de validación, las rutas, los hashes y los metadatos de procesamiento como salidas versionadas.

Cada ejecución se representa mediante una fila de `vectorization_events`, mientras que sus seis archivos externos se registran en `vectorization_artifacts`. `split_id` vincula la vectorización con el evento de partición, y `vectorization_id` la vincula con las matrices de entrenamiento y prueba, los archivos de índices de filas, el índice de características y el vectorizador ajustado. Las matrices grandes y los objetos binarios ajustados permanecen fuera de SQLite; las rutas, funciones, tamaños y hashes SHA-256 mantienen la trazabilidad. Los campos completos y los esquemas de artefactos se presentan en la especificación técnica complementaria.

Subtask 3.4: Implementación, entrenamiento y comparación de modelos

Después de la vectorización, la matriz de características de entrenamiento y sus correspondientes etiquetas validadas por personas se utilizan para entrenar un clasificador multiclase supervisado. El clasificador asigna cada enunciado candidato a una de las tres categorías definidas para la tarea 3: regulativo, constitutivo o no institucional.

La implementación no exige un algoritmo de clasificación específico. Los investigadores pueden utilizar Random Forest, máquinas de vectores de soporte, regresión logística, modelos transformer preentrenados u otros clasificadores supervisados, siempre que se mantengan los mismos requisitos de partición de datos, control de filtración de información, evaluación, versionado y trazabilidad. Esto permite adaptar el método de clasificación a medida que crece el corpus etiquetado o se dispone de modelos más adecuados.

Familia de modelos candidatos	Uso en el flujo de trabajo	Estado
Random Forest	Clasificador clásico de ensamble; familia del prototipo actual.	Implementado

Familia de modelos candidatos	Uso en el flujo de trabajo	Estado
Máquina de vectores de soporte / regresión logística	Clasificadores alternativos de características dispersas dentro del mismo diseño de partición y evaluación.	Alternativa permitida
Transformer preentrenado	Clasificador contextual alternativo cuando los datos y los recursos computacionales permiten su ajuste fino.	Alternativa permitida

La implementación actual utiliza clasificadores Random Forest. Esta decisión se basa en Wróblewska et al. (2023), quienes combinan características TF-IDF, clasificación supervisada y procedimientos de selección de características para clasificar enunciados institucionales. Random Forest también permite relaciones no lineales entre las características textuales, puede entrenarse con o sin ponderaciones de clase y proporciona medidas de importancia de las características.

La siguiente tabla presenta un breve ejemplo de los parámetros básicos de Random Forest utilizados en el prototipo de la implementación actual:

Parámetro	Implementación actual
Número de árboles	100
Criterio de división	Impureza de Gini
Profundidad máxima del árbol	Sin máximo predefinido
Observaciones mínimas necesarias para dividir un nodo	2
Observaciones mínimas por hoja terminal	1
Número de características consideradas en cada división	Raíz cuadrada de las características disponibles
Muestreo bootstrap	Se aplica
Semilla aleatoria	42

Estos parámetros describen el prototipo actual y no deben interpretarse como obligatorios para todas las aplicaciones del protocolo. Pueden evaluarse configuraciones alternativas de parámetros o algoritmos de clasificación dentro del mismo flujo de entrenamiento y comparación.

Selección de características

La representación TF-IDF completa puede contener una gran cantidad de características en relación con el número de enunciados etiquetados. Por lo tanto, la selección de características puede incorporarse al entrenamiento del modelo para reducir el ruido, mejorar la eficiencia computacional e identificar una representación más parsimoniosa.

La implementación actual evaluó tres estrategias generales de características:

Estrategia de características	Descripción
Selección de una cantidad fija de características	Se selecciona una cantidad predefinida de características a partir de los datos de entrenamiento mediante un criterio estadístico explícito.

Estrategia de características	Descripción
Vocabulario completo	El clasificador utiliza el espacio completo de características TF-IDF sin una etapa separada de selección de características.
Eliminación recursiva de características	El subconjunto de características se selecciona de forma iterativa según el desempeño del modelo dentro de la validación cruzada.

La implementación no exige que los investigadores evalúen exactamente estas tres estrategias. Sin embargo, cuando se utiliza selección de características, debe realizarse únicamente con información de la partición de entrenamiento.

La selección de características también debe incluirse dentro del proceso de validación cruzada. Seleccionar las características una sola vez a partir de la partición completa de entrenamiento antes de la validación cruzada permitiría que la información de los pliegues de validación influyera en el vocabulario seleccionado. En cambio, el selector debe ajustarse de forma independiente dentro de cada pliegue de entrenamiento y luego aplicarse al pliegue de validación correspondiente.

Entrenamiento del modelo

Una vez especificados el modelo candidato y la estrategia de selección de características, el flujo de trabajo resultante debe ajustarse utilizando únicamente las observaciones asignadas a la partición de entrenamiento. El flujo incluye el vectorizador TF-IDF ajustado que se produjo, cualquier procedimiento de selección de características y el clasificador. La partición de prueba no debe utilizarse para ajustar o modificar ningún componente del flujo de trabajo.

Cuando se evalúan múltiples configuraciones, cada una debe ajustarse de forma independiente utilizando las mismas observaciones de entrenamiento y semillas aleatorias reproducibles. Las estrategias de ponderación de clases y los parámetros del modelo deben registrarse como parte de su configuración. Posteriormente, la selección de características y el ajuste del clasificador deben repetirse dentro del procedimiento de validación cruzada interna descrito a continuación.

Validación cruzada interna

El desarrollo del modelo debe utilizar validación cruzada estratificada de k pliegues dentro de la partición de entrenamiento. La estratificación conserva la distribución relativa de enunciados regulativos, constitutivos y no institucionales entre los pliegues. Debe definirse e informarse el número de pliegues para cada implementación.

Siempre que sea posible, deben utilizarse los mismos pliegues al comparar configuraciones de modelos. Esto permite atribuir las diferencias de desempeño al clasificador, la estrategia de ponderación de clases o el procedimiento de selección de características, en lugar de a diferencias en la composición de los pliegues.

Para cada pliegue de validación cruzada, debe reproducirse el flujo completo de modelado:

1. Seleccionar las observaciones de entrenamiento y validación específicas del pliegue.
2. Ajustar cualquier procedimiento de selección de características utilizando únicamente las observaciones de entrenamiento específicas del pliegue.
3. Aplicar las características seleccionadas a las observaciones de validación específicas del pliegue.
4. Ajustar el clasificador utilizando las observaciones de entrenamiento específicas del pliegue.
5. Generar predicciones para las observaciones de validación específicas del pliegue.
6. Calcular las métricas de evaluación.

7. Almacenar las asignaciones a pliegues, las características seleccionadas, las predicciones y los resultados.

Cuando se utiliza eliminación recursiva de características u otro método de selección de características dependiente del modelo, se recomienda la validación cruzada anidada. El procedimiento interno de validación cruzada selecciona el subconjunto de características, mientras que el procedimiento externo estima el desempeño del flujo completo de selección de características y clasificación.

Evaluación con la partición de prueba

Después del desarrollo interno del modelo, cada configuración candidata puede ajustarse utilizando la partición completa de entrenamiento y evaluarse en la partición de prueba. El vectorizador TF-IDF ajustado y cualquier procedimiento de selección de características creado a partir de la partición de entrenamiento deben aplicarse a la partición de prueba sin volver a ajustarlos.

En la implementación actual se utilizan las siguientes medidas:

Indicador	Propósito en la comparación de modelos
Macro-F1 de validación cruzada	Mide el desempeño interno promedio entre los cinco pliegues de entrenamiento, otorgando igual importancia a las tres clases.
Macro-F1 de prueba	Mide el desempeño en los enunciados reservados en la partición de prueba.
Macro-F1 combinado	Media aritmética del macro-F1 de validación cruzada y del macro-F1 de prueba.
Brecha absoluta de desempeño	Diferencia absoluta entre el macro-F1 de validación cruzada y el macro-F1 de prueba; se utiliza como indicador de estabilidad del desempeño.
Precisión por clase	Mide con qué frecuencia son correctas las predicciones de cada clase.
Exhaustividad por clase	Mide cuántos enunciados pertenecientes a cada clase se identifican.
F1 por clase	Resume la precisión y la exhaustividad por separado para cada clase.
Matriz de confusión	Muestra qué clases se confunden con mayor frecuencia.
Exactitud y F1 ponderado	Se conservan como medidas descriptivas secundarias.
Cantidad de características seleccionadas	Registra la complejidad del modelo y el grado de reducción de características.

Macro-F1 es la métrica principal porque cada clase recibe igual importancia a pesar de las diferencias en su frecuencia. Los resultados por clase y la matriz de confusión deben inspeccionarse siempre para garantizar que un resultado agregado alto no oculte un desempeño deficiente en las clases constitutiva o no institucional.

El macro-F1 combinado y la brecha absoluta de desempeño proporcionan información complementaria. La puntuación combinada resume el desempeño en la validación cruzada interna y la partición de prueba, mientras que la brecha indica cuán consistente es el desempeño del modelo en ambos entornos de evaluación. La selección del modelo también debe considerar los resultados por clase, los patrones de confusión, el tamaño del conjunto de características y la coherencia metodológica con la aplicación prevista.

La comparación completa entre modelos candidatos, configuraciones de parámetros, estrategias de ponderación de clases, métodos de selección de características y resultados de prueba debe documentarse en un informe separado de implementación o evaluación de modelos. El protocolo

registra el procedimiento general de comparación, pero no exige reproducir los resultados experimentales completos en su texto principal.

Modelo seleccionado en la implementación actual

Para la implementación experimental actual, la evaluación de modelos identifica como modelo preferido un Random Forest sin ponderación de clases que utiliza eliminación recursiva de características con validación cruzada. La selección de este modelo es específica del conjunto de datos y de la implementación actuales. No establece que Random Forest o este subconjunto de características sean universalmente superiores. El procedimiento de comparación debe repetirse cuando el corpus etiquetado cambie sustancialmente, cuando se incorporen documentos de otras jurisdicciones o tipos documentales, o cuando se introduzcan clasificadores alternativos.

Resultados del modelo y trazabilidad

Cada ejecución de entrenamiento debe crear un evento de modelo que conserve la relación completa entre el conjunto de datos etiquetado, la partición de datos, el evento de vectorización, el procedimiento de selección de características, la configuración del modelo y los resultados de evaluación.

Cada ejecución de entrenamiento se registra en `model_events`, que almacena los identificadores de las etapas previas, la configuración del modelo candidato y de selección de características, el diseño de validación cruzada, los resúmenes de evaluación, la configuración seleccionada, las validaciones técnicas y el estado. Los modelos ajustados externos, las predicciones, las listas de características seleccionadas, los informes, las matrices de confusión, los resultados por pliegue y los gráficos se registran en `model_artifacts` con sus funciones, rutas, tamaños, hashes y marcas temporales.

El modelo ajustado, el selector de características, las predicciones, las matrices de confusión, las listas de características seleccionadas, los informes de evaluación y otras salidas técnicas deben almacenarse como artefactos de modelo versionados. Cada artefacto debe conservar su identificador de modelo, tipo de artefacto, ruta de archivo, hash de integridad y marca temporal de creación.

Una vez seleccionado un modelo e informados sus resultados, los artefactos de entrenamiento correspondientes no deben sobrescribirse. Cualquier cambio en el conjunto de datos, el vectorizador, las características, los parámetros, el clasificador, las ponderaciones de clases o el diseño de validación debe generar un nuevo evento de modelo y nuevos artefactos versionados.

Subtarea 3.5: Aplicación al corpus de candidatos no etiquetado

Después de seleccionar, fijar y versionar un modelo, este puede aplicarse a los enunciados candidatos no etiquetados producidos en la tarea 2. La etapa de aplicación debe conservar cada `statement_id` y `statement_text` original y almacenar la clase predicha, las puntuaciones o probabilidades de clase disponibles, los indicadores de confianza, `model_id`, las versiones de vectorización y del conjunto de datos, la marca temporal de predicción y el estado de revisión como una salida analítica separada. Las predicciones no deben sobrescribir los valores de `class_label` validados por personas. Este paso final de aplicación se especifica aquí, pero aún no se ha implementado en el proyecto actual.

Las predicciones deben tratarse como propuestas provisionales de codificación. Los casos de baja confianza o ambiguos pueden ingresar a una cola de revisión humana, y las correcciones validadas pueden incorporarse a una nueva versión del conjunto de datos etiquetado para un reentrenamiento posterior. Cada ciclo debe crear nuevas particiones, vectorizadores, selectores de características, eventos de modelo, artefactos y registros de predicción versionados, en lugar de modificar los resultados anteriores.

REFERENCIAS

- Brandsma, G. J., Blom-Hansen, J., van Hal, F., & Moodley, K. (2025). A sentence-based approach to measuring EU regulatory activity. *Journal of European Public Policy*. Advance online publication. <https://doi.org/10.1080/13501763.2025.2596122>
- Bushouse, B. K., Virgüez-Ruiz, S., Chakraborti, M., & Frey, S. (2026). Advancing text analysis for nonprofit research: Using semantic role labeling to automate Institutional Grammar coding of nonprofit laws and policies. *Nonprofit Policy Forum*, 17(1–2), 323–341. <https://doi.org/10.1515/npf-2024-0048>
- Crawford, S. E. S., & Ostrom, E. (1995). A grammar of institutions. *American Political Science Review*, 89(3), 582–600. <https://doi.org/10.2307/2082975>
- Dunlop, C. A., Kamkhaji, J. C., & Radaelli, C. M. (2019). A sleeping giant awakes? The rise of the Institutional Grammar Tool (IGT) in policy research. *Journal of Chinese Governance*, 4(2), 163–180. <https://doi.org/10.1080/23812346.2019.1575502>
- Frantz, C. K., & Siddiki, S. (2021). Institutional Grammar 2.0: A specification for encoding and analyzing institutional design. *Public Administration*, 99(2), 222–247. <https://doi.org/10.1111/padm.12719>
- Galik, C. S., & Johnson, B. A. (2026). Governance of climate-induced relocation in the US: An exploration of institutional complexity. *Review of Policy Research*, 43(2), Article e70081. <https://doi.org/10.1111/ropr.70081>
- Guimarães, G. M. C., da Silva, F. X. B., Queiroz, A. L., Marcacini, R. M., Faleiros, T. P., Borges, V. R. P., & Garcia, L. P. F. (2024). DODFMiner: An automated tool for named entity recognition from official gazettes. *Neurocomputing*, 568, Article 127064. <https://doi.org/10.1016/j.neucom.2023.127064>
- Heikkilä, T., & Weible, C. M. (2018). A semiautomated approach to analyzing polycentricity. *Environmental Policy and Governance*, 28(4), 308–318. <https://doi.org/10.1002/eet.1817>
- Kim, M., & Collins, B. K. (2026). Regional transportation planning through intergovernmental collective action: Does planning conformity with federal regulations improve regional air quality? *Public Works Management & Policy*, 31(3), 324–342. <https://doi.org/10.1177/1087724X261421903>
- Pieper, L., Virgüez, S., Schlager, E., & Schweik, C. (2023). The use of the Institutional Grammar 1.0 for institutional analysis: A literature review. *International Journal of the Commons*, 17(1), 256–270. <https://doi.org/10.5334/ijc.1214>
- Rice, D., Siddiki, S., Frey, S., Kwon, J. H., & Sawyer, A. (2021). Machine coding of policy texts with the Institutional Grammar. *Public Administration*, 99(2), 248–262. <https://doi.org/10.1111/padm.12711>
- Saketos, V., Pantazi, D.-A., & Koubarakis, M. (2024). The large language model GreekLegalRoBERTa. In *Proceedings of the 13th Hellenic Conference on Artificial Intelligence* (Article 18). Association for Computing Machinery. <https://doi.org/10.1145/3688671.3688770>
- Siddiki, S., & Frantz, C. K. (2022). The institutional grammar in policy process research. *Policy Studies Journal*, 50(2), 299–314. <https://doi.org/10.1111/psj.12466>
- Turaga, V. S. P., Pahi, T., Tjoa, S., Siami-Namini, S., & Namin, A. S. (2025). CO2 (Co-Compliance Officer): An LLM-based ontology-driven methodology for generating knowledge graphs and AI compliance checking. *IEEE Access*, 13, 210576–210606. <https://doi.org/10.1109/ACCESS.2025.3639228>

- Vannoni, M. (2022). A political economy approach to the grammar of institutions: Theory and methods. *Policy Studies Journal*, 50(2), 453–471. <https://doi.org/10.1111/psj.12427>
- Wróblewska, A., Pielniński, B., Seweryn, K., Sysko-Romańczuk, S., Saputa, K., Wichrowska, A., & Schreiber, H. (2023). Automating the analysis of institutional design in international agreements. In A. Kő & E. Francesconi (Eds.), *Electronic government and the information systems perspective* (pp. 68–84). Springer. https://doi.org/10.1007/978-3-031-36024-4_5